基于原始实车采集数据的标注有效数据筛选方案

1. 方案目标

本方案面向自动驾驶原始实车采集日志，目标是从连续采集的海量图像、点云、雷达、定位与车辆状态数据中，筛选出适合进入人工标注流程的高价值数据子集。筛选后的数据应同时满足以下要求：

- 传感器质量可靠，可支持稳定标注。
- 场景连续完整，适合检测、跟踪、占用、地图等任务。
- 样本具有较高标注价值，包含足够目标与有效交互。
- 数据分布均衡，覆盖不同地域、天气、光照和道路类型。
- 标注成本可控，优先保留高价值、高可标性样本。

---

2. 总体流程

建议采用如下六阶段流程：

原始日志 → 质量过滤 → 场景切片 → 场景打分 → 分层抽样 → 人工复核

对应实施步骤如下：

1. 原始日志接入
2. 硬性质量过滤
3. 连续场景切片
4. 场景价值打分
5. 分层均衡抽样
6. 人工质检与标注入库

---

3. 数据单元定义

PROF

为统一筛选粒度，建议定义三级数据单元。

3.1 Log

一次完整实车采集任务，对应一段连续驾驶日志，时长可为数十分钟至数小时。

3.2 Scene

从 `log` 中切出的连续时间片段，建议配置如下：

- 时长：20 s
- 滑窗步长：10 s 或 20 s

3.3 Keyframe

用于正式标注的关键帧，建议：

- 标注频率：2 Hz
- 即每 0.5 s 选择 1 帧用于人工标注
- 非关键帧保留为时序上下文，不要求全部人工标注

---

4. 第一阶段：硬性质量过滤

首先剔除根本不适合进入标注流程的数据段。

4.1 传感器完整性检查

每个时间窗口内检查：

- 多路相机是否齐全
- LiDAR 是否正常出点
- Radar 是否存在正常回波
- IMU、GPS、CAN 是否持续可用
- 是否存在显著丢包

建议阈值：

- 相机缺失率 > 5%：剔除
- LiDAR 丢帧率 > 5%：剔除
- Radar 丢帧率 > 10%：降级或剔除
- 定位连续失效 > 2 s：剔除

4.2 时间同步检查

过滤多传感器时间偏移过大的数据段。

建议阈值：

- 相机与 LiDAR 主时间戳偏差 > 50 ms：剔除
- Radar 与主参考时间偏差 > 100 ms：降级
- 连续异常超过 3 次：整段剔除

PROF

4.3 标定有效性检查

剔除内参、外参异常或疑似漂移的数据。

建议检查项：

- 相机投影与点云对齐误差
- 地面点拟合稳定性
- 相邻时段标定一致性
- 传感器安装姿态是否异常突变

若满足以下任一情况，则整段不进入标注池：

- 重投影误差均值超阈值
- 地平面估计波动过大

- 某一路相机长期外参失真

4.4 图像质量检查

过滤无法可靠标注的图像数据。

建议检查项：

- 严重模糊
- 过曝或欠曝
- 雨滴、污渍、大面积遮挡
- 强逆光导致目标难以辨识
- 夜间极暗导致可见目标过少

可用指标：

- Laplacian 方差：模糊评分
- 亮度均值与方差
- 饱和像素占比
- 污渍、雨滴检测模型输出分数

4.5 点云质量检查

过滤点云不可用的数据段。

建议检查项：

- 单帧点数过低
- 激光环缺失
- 噪声异常
- 近距离盲区异常增大
- 雨雾环境导致严重回波污染

建议指标：

- 总点数
- 有效距离内点数
- 地面点比例
- 动态点比例
- 噪声点比例

---

5. 第二阶段：场景切片

对通过质量过滤的 `log` 进行场景切片。

5.1 固定窗口切片

推荐采用固定长度切片：

- 每段 20 s

PROF

- 滑窗步长可设为 10 s 或 20 s

5.2 事件增强切片

可在固定切片之外叠加事件驱动切片，以提升高价值场景密度，例如：

- 路口通过
- 急转弯
- 并线
- 汇入汇出
- 紧急制动
- 行人密集区通行

5.3 切片约束

一个 `scene` 应满足：

- 时间连续
- 关键传感器完整
- 无明显同步异常
- 场景前后语义连贯
- 不跨越严重故障点

---

6. 第三阶段：场景价值打分

对每个 `scene` 计算标注收益分，用于后续排序与抽样。

6.1 可标注性分数 `S_quality`

反映该场景是否具备稳定标注条件，建议由以下因素组成：

- 图像清晰度
- 点云密度
- 时间同步质量
- 定位稳定性
- 标定可信度

6.2 目标丰富度分数 `S_object`

反映该场景中目标信息是否充分，建议组成如下：

- 平均每帧目标数
- 动态目标数
- 近距离目标数
- 可见目标持续时长
- 可连续跟踪目标数

6.3 交互复杂度分数 `S_interaction`

PROF

反映场景是否具备较高训练和评测价值，建议包括：

- 路口通行
- 跟车、变道、汇入汇出
- 行人横穿
- 非机动车混行
- 大车、公交、工程车交互
- 遮挡与解遮挡事件

6.4 长尾价值分数 `S_rare`

用于提升困难样本和稀有样本比例，例如：

- 夜间场景
- 雨天、湿滑路面
- 施工区域
- 特殊车辆
- 异形障碍物
- 稀有交通参与者

6.5 多样性分数 `S_diversity`

用于避免场景重复，控制冗余数据，例如：

- 同一路段长直行场景
- 同质化车流
- 长时间停车等待
- 低信息量巡航

6.6 综合评分公式

建议采用可解释线性加权模型：

$$
S = w_1 S_{quality} + w_2 S_{object} + w_3 S_{interaction} + w_4 S_{rare} + w_5 S_{diversity}
$$

可参考初始权重：

- $w_1 = 0.30$
- $w_2 = 0.20$
- $w_3 = 0.20$
- $w_4 = 0.15$
- $w_5 = 0.15$

若标注预算有限，可适当提高 `S_rare` 和 `S_interaction` 权重。

---

7. 第四阶段：规则化筛选条件

在打分前后增加规则门控，提升候选池质量稳定性。

7.1 准入条件

必须同时满足以下条件才允许进入候选池：

- 关键传感器完整
- 同步误差在阈值内
- 标定正常
- 连续时长达到 20 s
- 图像与点云质量合格
- 无大面积隐私遮挡或数据损坏

7.2 一票否决条件

若出现以下情况，直接剔除：

- 相机大面积黑屏
- LiDAR 严重失真或无点
- 多传感器长期不同步
- 定位轨迹明显跳变
- 标定失效
- 关键目标完全不可见
- 雨雪、泥污导致大部分帧不可用

---

8. 第五阶段：分层均衡抽样

高分场景不能直接全选，否则容易造成分布偏斜。应对候选场景进行分层均衡抽样。

8.1 分层维度

建议按如下维度建立配额：

PROF

- 城市或区域
- 道路类型
  - 高速
  - 城市主干道
  - 次干道
  - 园区道路
  - 停车场
- 光照条件
  - 白天
  - 黄昏
  - 夜间
- 天气条件
  - 晴天
  - 阴天
  - 雨后

    - 小雨
- 交通密度
    - 稀疏
    - 中等
    - 拥堵
- 目标类型
    - 车辆为主
    - 行人为主
    - 非机动车混行
    - 大车密集
- 特殊事件
    - 路口
    - 变道
    - 横穿
    - 施工

8.2 抽样策略

每个分层桶内：

1. 先按质量准入过滤
2. 再按综合得分排序
3. 保留 Top-K
4. 对高度相似场景做去重

---

9. 第六阶段：相似场景去重

为避免“高分但重复”的样本大量进入标注池，需要引入去重模块。

9.1 去重依据

可从以下维度构造场景特征：

- 位置网格
- 车速分布
- 转向模式
- 目标类别直方图
- 目标轨迹统计
- 图像语义特征
- BEV 栅格占用特征

9.2 去重方法

可采用以下方式：

- 余弦相似度筛重
- 聚类后每簇保留代表场景
- 同一路段相邻窗口仅保留得分更高者

建议规则：

- 相似度 > 0.95：只保留 1 个
- 对重叠窗口内容高度相似的场景，仅保留高分窗口

---

10. 第七阶段：关键帧选取策略

选定 `scene` 后，不建议逐帧全量人工标注。

10.1 推荐配置

- 场景长度：20 s
- 关键帧频率：2 Hz
- 每个 `scene` 约 40 帧标注

10.2 数据保留策略

- 关键帧：进入正式标注流程
- 非关键帧：保留为 `sweeps` 或时序上下文

该策略有利于：

- 多帧检测
- 跟踪任务
- 时序建模
- 占用预测
- 地图建模

---

11. 推荐指标表

11.1 质量类指标

- 图像模糊分
- 亮度异常比例
- 点云有效点数
- 同步误差
- 标定对齐误差
- GNSS/IMU 稳定性

11.2 目标类指标

- 平均每帧目标数
- 动态目标数
- 稀有类目标数
- 近距离目标数
- 可连续跟踪目标数

11.3 交互类指标

PROF

- 路口通过事件数
- 行人横穿事件数
- 非机动车交汇事件数
- 并线或汇入事件数
- 紧急制动或急转向事件数

11.4 长尾类指标

- 夜间标签
- 雨天标签
- 遮挡程度
- 施工区标签
- 大车比例
- 特殊障碍物标签

---

12. 标注池分级建议

建议将候选样本分为三级。

12.1 A级：优先标注

满足以下特征：

- 数据质量高
- 交互复杂
- 长尾价值高
- 分布稀缺

用于构建核心标注集。

12.2 B级：补充分布

数据质量良好，但复杂度相对一般。用于平衡整体数据分布。

PROF

12.3 C级：预备池

质量勉强合格或信息量一般。仅在预算充足时补充。

---

13. 人工复核流程

自动筛选后必须进行人工复核。

13.1 复核重点

- 场景是否连续完整
- 关键目标是否可见
- 是否存在不可控的标注困难
- 是否与已选场景重复

- 是否满足当前任务定义

13.2 建议抽检比例

- A级：10% 抽检
- B级：20% 抽检
- C级：30% 抽检

若为首版数据集，建议首轮全量审核。

---

14. 输出物设计

最终建议输出以下四类结果。

14.1 候选场景表

字段建议：

- `log_id`
- `scene_id`
- `start_ts`
- `end_ts`
- `quality_score`
- `object_score`
- `interaction_score`
- `rare_score`
- `diversity_score`
- `final_score`
- `city`
- `weather`
- `time_of_day`
- `road_type`
- `traffic_density`
- `selected_flag`

PROF

14.2 关键帧索引表

建议字段：

- `scene_id`
- `keyframe_ts`
- `sensor_paths`
- `pose`
- `calib_version`

14.3 剔除原因表

记录样本被剔除的具体原因，例如：

- 传感器缺失
- 同步异常
- 标定异常
- 图像模糊
- 点云过稀
- 场景重复
- 信息量不足

14.4 数据分布报表

统计最终入选数据在以下维度的分布：

- 类别分布
- 地域分布
- 白天与夜间分布
- 天气分布
- 场景复杂度分布
- 稀有类分布

---

15. 推荐落地策略

若需要快速启动，建议先使用以下工程初始版策略。

15.1 阶段一：硬过滤

剔除以下问题数据：

- 传感器丢帧严重
- 时间同步异常
- 标定异常
- 图像严重模糊或过曝
- 点云极度稀疏
- 定位轨迹跳变

PROF

15.2 阶段二：20 s 切片

将通过过滤的连续日志按 20 s 切分为 scene。

15.3 阶段三：场景打分

采用如下综合分：

$$
S = 0.3S_{quality} + 0.2S_{object} + 0.2S_{interaction} + 0.15S_{rare} + 0.15S_{diversity}
$$

15.4 阶段四：分层抽样

按以下维度做均衡抽样：

- 城市
- 白天与夜晚
- 晴天与雨天
- 路口与非路口
- 稀有目标占比

15.5 阶段五：关键帧标注

对入选 scene 按 2 Hz 选取关键帧进行人工标注。

---

16. 面向项目落地的实施流程图

以下流程图面向工程实施，覆盖从原始日志接入到标注入库的完整闭环。

```
原始实车日志接入
  ↓
元数据解析与索引构建
  ↓
传感器完整性检查
  ↓
时间同步检查
  ↓
标定有效性检查
  ↓
图像与点云质量检查
  ↓
是否通过硬性质量过滤？
  |-- 否 -> 记录剔除原因并写入剔除表
  `-- 是 -> 按固定窗口切分 Scene
            -> 事件检测与事件增强切片
            -> 场景综合评分计算
            -> 应用规则门控与一票否决
            -> 是否进入候选池？
               |-- 否 -> 写入候选失败原因
               `-- 是 -> 多维分层抽样
                         -> 分层排序与 Top-K 抽样
                         -> 相似场景聚类与去重
                         -> 生成待标注 Scene 列表
                         -> 按 2 Hz 抽取 Keyframe
                         -> 人工复核与抽检
                         -> 复核是否通过？
                            |-- 否 -> 退回修正或从候选池移除
                            `-- 是 -> 导出标注任务包
                                      -> 标注入库与版本冻结
                                      -> 生成分布报表与质检报告
```

16.1 工程模块拆分建议

PROF

建议将整套流程拆分为以下模块：

1. `ingest`：原始日志接入、索引构建、元数据解析。
2. `quality_gate`：完整性、同步、标定、图像与点云质量检查。
3. `scene_builder`：固定窗口切片与事件增强切片。
4. `scene_scorer`：计算质量分、目标分、交互分、长尾分、多样性分。
5. `sampler`：分层抽样、配额控制、相似场景去重。
6. `review`：人工抽检、问题回流、候选池修正。
7. `exporter`：导出标注任务、关键帧索引、场景分布报表。

16.2 推荐落地顺序

推荐按以下顺序逐步上线：

1. 先完成硬性过滤与固定窗口切片。
2. 再补充场景打分和简单 Top-K 排序。
3. 随后加入分层抽样和相似场景去重。
4. 最后接入人工复核、报表导出和版本冻结机制。

这样可以先跑通可用的最小闭环，再逐步增强筛选精度。

---

17. 面向项目落地的筛选规则表

下表给出一版可直接落地的初始筛选规则。项目实施时可根据传感器规格、采集平台和任务目标进一步调整。

规则 ID	规则类别	指标	条件	建议阈值	动作	说明
R001	完整性	相机缺失率	>	0.05	reject	任一关键相机长期缺失直接剔除
R002	完整性	LiDAR 丢帧率	>	0.05	reject	LiDAR 为主传感器时严格控制
R003	完整性	Radar 丢帧率	>	0.10	downgrade/reject	先降级，严重时剔除
R004	定位	GNSS/IMU 连续失效时长	>	2.0 s	reject	无法保证姿态连续性
R005	同步	Camera-LiDAR 时间偏差	>	50 ms	reject	影响多传感器配准
R006	同步	Radar-主时钟时间偏差	>	100 ms	downgrade	轻度异常可降级处理
R007	标定	重投影误差均值	>	3.0 px	reject	相机与点云对齐明显异常
R008	标定	地平面法向波动	>	5.0 deg	reject	标定或姿态可能异常

PROF

规则 ID	规则类别	指标	条件	建议阈值	动作	说明
R009	图像质量	模糊评分	<	100.0	reject	可使用 Laplacian 方差
R010	图像质量	过曝像素占比	>	0.25	reject	大面积高亮区域不可标
R011	图像质量	欠曝像素占比	>	0.35	reject	夜间极暗场景需剔除
R012	图像质量	雨滴/污渍分数	>	0.60	reject	镜头遮挡严重
R013	点云质量	单帧有效点数	<	30000	reject	点云过稀导致标注困难
R014	点云质量	噪声点比例	>	0.15	reject	雨雾或异常回波过多
R015	场景切片	Scene 连续时长	<	20.0 s	reject	不满足标准切片时长
R016	目标丰富度	平均每帧目标数	<	3	downgrade	信息量不足，降级候选
R017	目标丰富度	动态目标数	<	1	downgrade	用于压缩低价值巡航段
R018	交互复杂度	路口/并线/横穿事件数	<	1	keep	非必需，不作剔除，仅影响得分
R019	长尾价值	夜间/雨天/施工标签	==	true	bonus	稀有场景给予额外加分
R020	去重	场景相似度	>	0.95	deduplicate	仅保留高分代表样本
R021	关键帧	Keyframe 采样频率	=	2 Hz	export	输出正式标注帧
R022	复核	人工抽检未通过	==	true	reject/rollback	从标注池移除或退回修正

17.1 规则优先级建议

- `reject`：直接剔除，不进入候选池。
- `downgrade`：进入低优先级候选池，仅在配额不足时补充。
- `bonus`：不改变准入资格，仅在最终排序时加分。
- `deduplicate`：用于相似样本去重。
- `export`：用于导出关键帧或标注任务。

17.2 规则实施建议

PROF

1. 硬性质量类规则在 scene 切片前执行。
2. 目标丰富度和交互复杂度规则在 scene 切片后执行。
3. 去重规则在分层抽样之后执行。
4. 人工复核规则作为最终入库前的最后关卡。

---

18. JSON/YAML 配置模板

为便于工程落地，建议将筛选逻辑配置化。以下给出一版推荐模板，可直接作为配置文件初稿使用。

18.1 JSON 配置模板示例

对应文件可保存为 docs/annotation_filter_config.template.json。

```
{
  "project": {
    "name": "apollo_annotation_filter",
    "version": "1.0.0",
    "description": "Raw driving log filtering for annotation-ready
scenes"
  },
  "scene": {
    "duration_sec": 20,
    "stride_sec": 10,
    "keyframe_hz": 2
  },
  "quality_gate": {
    "sensor_integrity": {
      "camera_missing_rate_max": 0.05,
      "lidar_drop_rate_max": 0.05,
      "radar_drop_rate_max": 0.10,
      "localization_failure_sec_max": 2.0
    },
    "time_sync": {
      "camera_lidar_offset_ms_max": 50,
      "radar_master_offset_ms_max": 100,
      "continuous_anomaly_count_max": 3
    },
    "calibration": {
      "reprojection_error_px_max": 3.0,
      "ground_normal_jitter_deg_max": 5.0
    },
    "image_quality": {
      "blur_score_min": 100.0,
      "over_exposure_ratio_max": 0.25,
      "under_exposure_ratio_max": 0.35,
      "occlusion_score_max": 0.60
    },
    "pointcloud_quality": {
      "valid_points_min": 30000,
      "noise_ratio_max": 0.15
```

PROF

```
      }
    },
    "scoring": {
      "weights": {
        "quality": 0.30,
        "object": 0.20,
        "interaction": 0.20,
        "rare": 0.15,
        "diversity": 0.15
      },
      "minimums": {
        "avg_objects_per_frame": 3,
        "dynamic_objects_per_scene": 1
      },
      "bonus": {
        "night_scene": 0.05,
        "rain_scene": 0.05,
        "construction_zone": 0.05,
        "rare_object_scene": 0.08
      }
    },
    "sampling": {
      "quotas": {
        "day": 0.50,
        "night": 0.20,
        "rain": 0.10,
        "intersection": 0.20
      },
      "deduplication": {
        "enabled": true,
        "similarity_threshold": 0.95,
        "keep": "highest_score"
      }
    },
    "review": {
      "a_level_sample_ratio": 0.10,
      "b_level_sample_ratio": 0.20,
      "c_level_sample_ratio": 0.30,
      "reject_on_manual_fail": true
    },
    "outputs": {
      "export_keyframes": true,
      "export_scene_table": true,
      "export_reject_report": true,
      "export_distribution_report": true
    }
  }
```

PROF

18.2 YAML 配置模板示例

对应文件可保存为 docs/annotation_filter_config.template.yaml。

```yaml
project:
  name: apollo_annotation_filter
  version: 1.0.0
  description: Raw driving log filtering for annotation-ready scenes

scene:
  duration_sec: 20
  stride_sec: 10
  keyframe_hz: 2

quality_gate:
  sensor_integrity:
    camera_missing_rate_max: 0.05
    lidar_drop_rate_max: 0.05
    radar_drop_rate_max: 0.10
    localization_failure_sec_max: 2.0
  time_sync:
    camera_lidar_offset_ms_max: 50
    radar_master_offset_ms_max: 100
    continuous_anomaly_count_max: 3
  calibration:
    reprojection_error_px_max: 3.0
    ground_normal_jitter_deg_max: 5.0
  image_quality:
    blur_score_min: 100.0
    over_exposure_ratio_max: 0.25
    under_exposure_ratio_max: 0.35
    occlusion_score_max: 0.60
  pointcloud_quality:
    valid_points_min: 30000
    noise_ratio_max: 0.15

scoring:
  weights:
    quality: 0.30
    object: 0.20
    interaction: 0.20
    rare: 0.15
    diversity: 0.15
  minimums:
    avg_objects_per_frame: 3
    dynamic_objects_per_scene: 1
  bonus:
    night_scene: 0.05
    rain_scene: 0.05
    construction_zone: 0.05
    rare_object_scene: 0.08

sampling:
  quotas:
    day: 0.50
    night: 0.20
```

PROF

```yaml
      rain: 0.10
      intersection: 0.20
    deduplication:
      enabled: true
      similarity_threshold: 0.95
      keep: highest_score

  review:
    a_level_sample_ratio: 0.10
    b_level_sample_ratio: 0.20
    c_level_sample_ratio: 0.30
    reject_on_manual_fail: true

  outputs:
    export_keyframes: true
    export_scene_table: true
    export_reject_report: true
    export_distribution_report: true
```

18.3 配置字段使用建议

1. 质量过滤阈值单独维护，便于按车型、传感器批次调整。
2. 场景评分权重建议通过历史标注效果持续校准。
3. 抽样配额建议由数据管理与算法团队联合维护。
4. 所有配置变更都应带版本号，并与导出的标注批次绑定。

---

19. 结论

本方案的核心思想是：先利用传感器完整性、时间同步、标定、图像质量和点云质量进行硬性过滤；再将连续日志切分为固定时长 `scene`；从可标注性、目标丰富度、交互复杂度、长尾价值和多样性五个维度进行打分；随后按地域、天气、光照、道路类型和交通密度进行分层均衡抽样；最后仅对入选场景中的关键帧执行人工标注，而将非关键帧作为时序上下文保留。

PROF

在项目实施层面，建议优先落地“质量过滤 → 场景切片 → 场景打分 → 分层抽样 → 人工复核 → 标注导出”的最小闭环，并通过规则表和配置文件实现阈值、配额、权重的统一管理与持续迭代。

该流程能够在保证标注质量的前提下，提高样本有效性、数据集代表性和标注资源利用效率。